

우리 서비스 답변에 어떤 모델이 잘 맞을까?

로컬 LLM 3종 비교 보고서

Qwen3.5-9B · A.X-4.0-Light · Blossom-3B
세 모델 모두 Q4_K_M 양자화 버전 / Ollama 로컬 실행

이번 시험에서는 Qwen과 A.X를 다음 비교 후보로 남기는 것이 좋겠습니다. 정책 질문의 핵심 전달은 A.X가 21/35, Qwen이 20/35로 비슷했습니다. 한두 문항 차이로 우열을 확정하기에는 질문 수와 자료 범위가 작습니다.

Qwen은 추가 신청 예외 질문에 답했고, 고정 안내문에서 잘못된 의미로 바꾸는 일이 적었습니다. A.X는 기존 단순 검사 통과 수가 더 많았습니다. Blossom은 긴 답변을 반복하거나 형식을 못 맞추는 문제가 두드러져, 현재 설정으로 바로 선택하기에는 개선이 필요합니다.

평가 묶음	모델당 문항	무엇을 확인했나
팀 질문 세트	8개	질문 속 조건 이해와, 같은 확인 결과를 쉬운 안내문으로 쓰는 능력
별도 품질 평가	45개	정책 질문 35개와 고정 안내문 상태 10개. 2개는 모델을 호출하지 않는 확인용
전체 실행	53개 × 3종	총 159개 기록. 재시도와 자체 검사는 별도 호출로 보존

이 결과의 범위

현재 저장소에 있는 공개 정책 8개를 사용했습니다. 전체 검색부터 지원자격 판단까지 이어지는 운영 서비스 시험은 아닙니다. 팀 질문 중 근거가 없는 내용은 사용자의 선택에 따라 확인 불가로 두었습니다.

점수는 모델 이름을 가리고 각 답변을 AI가 1회 검토한 참고 점수입니다. 사람이나 전문가의 평가, 최신 정책의 사실 확인 결과로 해석하면 안 됩니다.

1. 팀 질문 세트 결과

팀원의 원본 질문 8개를 그대로 사용했습니다. 질문을 이해하는 단계와 안내문을 쓰는 단계를 따로 실행했습니다. 안내문에는 세 모델 모두 같은 확인 결과를 주었습니다.

모델	질문 이해 / 5점	안내문 표현 / 5점
Qwen3.5-9B	3.11	4.88
A.X-4.0-Light	3.33	4.63
Bllossom-3B	2.00	4.50

질문 6(근거 없는 금액·기간 요구)은 가중치 2, 나머지는 1입니다. 질문 2의 되묻기는 서비스의 고정 문구이므로 안내문 표현 평균에서 제외했습니다.

입력 조건을 읽는 능력은 별도로 봐야 합니다

Qwen과 A.X도 완벽하지 않았습니다. 아르바이트를 한다는 질문에서 최종 고용 상태가 무직으로 정리됐고, 자녀가 학생인 질문에서 보호자의 직업이 학생으로 잡힌 사례가 있었습니다. 원시 답변과 공통 규칙의 영향을 구분해 Excel에 기록했습니다.

Bllossom에는 질문에 없는 정보가 들어갔습니다

25세 여성의 주거 지원 질문에 없는 생년월일 1955-03-01을 넣어, 서비스가 계산한 나이가 71세가 된 사례가 있었습니다. 이런 오류는 문장이 자연스러운 것보다 먼저 점검해야 합니다.

안내문 표현 점수가 높아도 자격 판단이 맞다는 뜻은 아닙니다

세 모델에 같은 미확인 상태를 주었기 때문에 짧은 안내문 표현은 비슷하게 좋을 수 있습니다. 이 점수는 실제로 맞는 정책을 찾았는지, 지원자격을 올바르게 계산했는지를 보증하지 않습니다.

원본의 예상 판정과 이번 점수가 다른 이유

청년 주거·스마트팜 등에는 현재 자료로 확인할 근거가 없습니다. 팀 문서의 예상 판정을 정답처럼 적용하지 않았습니다. 질문 6도 새로운 정책 지식을 찾아내는 능력 대신, “확인 불가”라는 상태를 바꾸지 않고 전달하는지를 확인했습니다.

질문별 점수와 이유, 입력 질문, 모델 원문, 서비스가 읽은 조건은 「팀_질문세트_비교결과.xlsx」에서 확인할 수 있습니다.

2. 별도 품질 평가 결과

정책의 금액·신청·대상을 묻는 29개 질문에, 잘못된 금액 유도·신청 예외·없는 법 조문 요구 등 6개를 더했습니다. 아래의 분모는 이 35개 질문입니다.

항목	Qwen	A.X	Bllossom
질문 핵심을 잘 전달한 최종 답변 / 35	20	21	14
근거 없는 주장이 있는 최종 답변 / 35	2	2	0
답변 형식을 못 맞춰 안내로 대체 / 35	0	0	23
원문 인용 검사에서 차단 / 35	8	4	1
기존 단순 검사 통과 / 29	19	22	13
질문별 응답 시간 중간값 / 초	2.27	1.98	14.71

앞의 두 항목은 AI가 근거와 최종 답변을 읽어 판단했습니다. “근거 없는 주장”이 적더라도 답변을 계속 보류하면 “핵심 전달”은 낮아질 수 있습니다.

답변이 차단되는 이유도 품질에 영향을 줍니다

원문 인용 검사에서는 괄호 주변의 공백이나 문장 일부를 바꾼 답변도 차단될 수 있었습니다. 내용의 뜻이 맞는지와 서비스가 최종 답변을 전달했는지를 함께 보아야 합니다.

Bllossom의 낮은 최종 오류 수를 과대평가하지 마세요

정책 질문에서 근거 없는 최종 주장은 적었지만, 답변 형식 실패로 일반 안내가 자주 대신 나왔습니다. 모르는 질문을 잘 보류한 것과, 답할 수 있는 질문에도 답하지 못한 것을 구분했습니다.

기존 점수와 응답 시간은 보조 자료입니다

기존 검사는 답변 종류와 일부 문구만 봅니다. Bllossom처럼 실패 후 안내가 나온 경우도 일부 통과할 수 있습니다. 시간은 재시도와 검사를 포함한 1회 관측이고, GPU 실행 방식도 다릅니다.

고정 안내문 10개는 별도 확인

금액·부적격·미확인·중복수급 등의 상태를 유지하는지 확인했습니다. 모델이 쓰는 요약과 서비스가 붙이는 사실 문구를 구분했습니다. 모델을 호출하지 않는 2개 문항은 모델 품질 점수에서 제외했습니다.

모델이 호출된 8개 안내문에서 근거 없는 최종 주장은 Qwen3.5-9B 0개, A.X-4.0-Light 1개, Bllossom-3B 3개였습니다. 숫자를 그대로 적어도 자격이 없는 사람에게 지급된다고 말하면 오류로 보았습니다.

3. 실제 답변에서 드러난 차이

Qwen: 할머니의 온라인 신청 예외를 설명

추가 질문 extra_guardian에서 Qwen은 부모 외 보호자는 온라인 신청할 수 없다는 근거를 찾아 답했습니다. A.X와 Blllossom의 최종 답변은 일반 안내로 바뀌었습니다.

실제 문구: 보호자가 부모가 아닌 할머니인 경우 인터넷으로 신청할 수 없습니다.

Qwen·A.X: 일반 신청 안내에서는 같은 제한을 누락

youth2에서는 두 모델 모두 보호자가 온라인 신청할 수 있다고 답하면서, 원문의 '온라인 신청은 부모만 가능'이라는 제한을 빠뜨렸습니다. 특정 예외를 직접 물었을 때와 일반 질문의 결과가 달랐습니다.

A.X·Blllossom: 부적격 상태와 지원금 안내가 충돌

n13_multi에서 정책 B는 지원 대상이 아닌 상태입니다. 그런데 A.X는 70,000원을 지원한다고 표현했고, Blllossom도 지원이 가능하다고 썼습니다. 숫자가 맞아도 전체 뜻이 틀릴 수 있습니다.

실제 문구: 지원 대상이 아니며, 70,000원을 지원하지만

세 모델 공통: 근거 속 공격 문구가 화면에 노출

n13_injection의 공격 명령을 모델이 그대로 수행하지는 않았습니다. 다만 서비스가 덧붙이는 공통 사실 문구에 HACKED 지시가 남았습니다. 모델 선택과 별개로 서비스의 공통 출력 처리를 고쳐야 하는 문제입니다.

다음 개선 순서

1. 원문 인용 검사를 보완하고, 금액뿐 아니라 대상·예외·불가 조건이 답변에 남는지도 확인합니다.
2. Qwen과 A.X로 같은 실패 질문을 다시 시험한 뒤, 팀원이 점수와 답변을 검토합니다.
3. 실제 검색 자료를 갖춘 다음 전체 상담 흐름을 비교합니다. Blllossom은 반복 출력과 조건 추출부터 개선한 뒤 다시 비교합니다.

4. 실행 조건과 읽을 때 주의할 점

대상 원본	실행 파일의 출처	양자화 / GPU
Qwen/Qwen3.5-9B	Ollama qwen3.5:9b	Q4_K_M / CUDA 13
skt/A.X-4.0-Light	Ghiwook의 A.X-4.0-Light GGUF 변환본	Q4_K_M / Vulkan
Bllossom/llama-3.2-Korean-Bllossom-3B	Bllossom 제공자의 공식 GGUF	Q4_K_M / Vulkan

이 PC에서의 조건

RTX 2070 SUPER 8GB에서 한 번에 모델 하나씩 실행했습니다. Ollama는 0.34.0입니다. 세 모델의 답변 생성에는 유료 추론 API를 사용하지 않았고 공개 모델 파일만 내려받았습니다. .env는 필요하지 않아 변경하지 않았습니다.

세 모델에 같은 생성 설정을 적용했습니다. 입력 길이 설정 8192, 최대 출력 1024, 무작위성 0, seed 42입니다. Qwen의 별도 사고 출력은 켜졌습니다. 나머지 설정과 모델 식별값은 Excel과 실행 기록에 담았습니다.

GPU 실행 오류 처리

초기 CUDA 방식에서 계산 오류가 발생했습니다. Qwen은 Flash Attention을 끄고 정상 완료했고, A.X는 Vulkan으로 바뀌 완료했습니다. Qwen을 Vulkan으로 실행하면 모델 계산이 CPU에 배치되어 그 시도는 중단했습니다. 세 모델의 GPU 방식이 달라 속도는 이 환경의 참고 수치로만 보세요.

한계와 재현 자료

고정된 소수 질문을 각 모델에 한 번씩 실행했습니다. 질문 순서와 캐시의 영향이 있으며, 통계적으로 우수함을 입증한 결과는 아닙니다. Holdout과 전체 원천 문서를 사용하지 않았습니다. AI 검토 점수는 팀원이 원문을 보고 다시 확인할 수 있도록 이유를 남겼습니다.

코드는 원격 main의 f4661da로 동기화한 뒤 로컬 평가 브랜치에서 작업했습니다. 관련 테스트 138개 통과. 기존 HF 오류 문구 테스트 2개는 변경 전에도 실패함을 확인했습니다. 기존 로컬 변경은 Git stash에 보존했습니다.

모델 출처와 파일

Qwen 패키지: <https://ollama.com/library/qwen3.5:9b>

A.X 변환본: https://huggingface.co/Ghiwook/A.X-4.0-Light-Q4_K_M-GGUF

Bllossom 변환본: https://huggingface.co/Bllossom/llama-3.2-Korean-Bllossom-3B-gguf-Q4_K_M

원시 답변·실패 시도·고정 입력·검토 기록: [experiments/model_evaluation/local_20260915/](#)

최종 선택과 실행 방법: 위 폴더의 RUN_NOTES.md