

LLM 답변 품질 비교

RunPod 중간결과 | 2026-09-16 | 동일 44문장

중간결과: 세 모델이 모두 완료한 동일 문장만 비교합니다. 일부 말투·조건이 더 많아 전체 60문장 결과로 볼 수 없습니다. 같은 상황의 세 말투를 모두 맞힌 비율은 계산하지 않았습니다.

모델	실제 완료/계획	공통 N	집계 제외	성공	근거 없음
Qwen3.5-9B	60/60	44	16	15	0
A.X-4.0-Light	60/60	44	16	14	7
Bllossom-3B	44/60	44	0	0	0

Qwen3.5-9B: 조건 이해 4.43 / 5 (35개), 없는 조건 추가 3개. 표현 4.68 / 5 (38개).

A.X-4.0-Light: 조건 이해 3.91 / 5 (35개), 없는 조건 추가 11개. 표현 4.75 / 5 (32개).

Bllossom-3B: 조건 이해 1.00 / 5 (35개), 없는 조건 추가 44개. 표현 4.00 / 5 (9개).

성공은 도움이 되면서 근거 없는 주장이 없는 최종 답변입니다. 조건 이해·표현 평균은 해당 점수가 있는 답변만 대상으로 하며 분모가 다를 수 있습니다.

모델명을 가린 검토 원본과 수정 이력은 보존했습니다. 문장별 답변과 검토 이유는 엑셀에서 확인할 수 있습니다.

파일 변경 여부를 확인하는 값과 원본은 ZIP에 있습니다.

실행 조건과 해석 한계

동일 RunPod NVIDIA RTX A5000 24GB에서 세 모델을 순차 실행했습니다. 모두 Q4_K_M 양자화 모델이며, A.X는 Ghiwook의 배포본입니다. 출력 제한은 호출당 1024토큰, 문맥은 8192토큰, temperature는 0입니다.

LLM_DISABLE_THINKING에 해당하는 설정은 true입니다. Qwen에는 think:false를 보냈고, 해당 옵션을 지원하지 않는 A.X와 Bllossom에는 생략했습니다. 완료된 모든 문장에서 모델 전체가 GPU 메모리에 올라간 기록을 확인했습니다.

Bllossom은 추가 사용 시간의 답변이 없어 한국시간 9월 16일 04:47에 중단했습니다. 안내한 04:40보다 중단이 늦었습니다. 그때의 미완료 호출은 별도 보존하고 점수에서 제외했습니다. Pod 자체는 중지하지 못했습니다.

질문 종류·말투의 균형과 상황당 세 표현 완성을 보장하지 않습니다. 전체 60문장·300문항·실제 사용자 성능으로 일반화하지 않습니다. 검색 전체 서비스 시험도 아닙니다.

100가지 상황을 세 말투씩 바꾼 300문장에서 20가지 상황·60문장을 골랐습니다. 이번 공통 44문장에는 8개 정책과 10가지 말투가 포함됩니다. 같은 상황의 표현 변형이 있어 서로 독립적인 44사례는 아닙니다. 팀원 질문 8개는 이전 결과로 보존하며 이번 점수에 합치지 않았습니다.

질문에서 나이·지역 등을 읽는 단계(N1)와 상세 답변은 따로 시험했습니다. 동일 정책 문서를 주었으며, 문서를 찾는 검색 단계는 시험하지 않았습니다. 모델명을 가린 별도 AI가 검토했고 일부 사례를 재확인했습니다. 사람 전문가의 확정 판정은 아닙니다.

표현 점수는 읽을 수 있는 생성문장에만 매겼습니다. 서비스 검사에서 차단된 문장도 포함하므로, 표현 점수가 높아도 사용자에게 좋은 답변이 전달됐다는 뜻은 아닙니다.

Qwen3.5-9B: 같은 44개 처리 평균 15.5초, 모델 호출 117회 중 출력 한도 도달 0회.

A.X-4.0-Light: 같은 44개 처리 평균 8.6초, 모델 호출 115회 중 출력 한도 도달 0회.

Bllossom-3B: 같은 44개 처리 평균 39.4초, 모델 호출 131회 중 출력 한도 도달 58회.

결과 해석과 실제 답변

Qwen은 성공 15/44개, A.X는 14/44개였습니다. 1개 차이이므로 성공 수만으로 우승 모델을 정하기는 어렵습니다. 다만 근거 없는 최종 주장은 Qwen 0개, A.X 7개였고, 조건 이해 평균은 각각 4.43점과 3.91점입니다.

Bllossom은 44개 모두 사용자에게 실질적인 답변을 전달하지 못했습니다. 35개는 답변 형식 처리 실패, 나머지 9개는 서비스 검사에서 차단됐습니다. 호출 131회 중 58회가 출력 한도에 닿았습니다. 여러 답변 객체를 반복한 사례가 있어 지연에 영향을 줬습니다.

Bllossom의 근거 없는 최종 주장 0개는 좋은 답변을 했다는 뜻이 아닙니다. 모든 최종 응답이 일반 안내였기 때문입니다. 개인 조건을 읽는 단계에서는 44개 모두 질문에 없는 조건을 추가했습니다. 현재 형식·설정과의 적합성 결과로 해석해야 합니다.

A.X의 이전 Fleet 반복은 이번 60문장의 162회 호출에서 나타나지 않았습니다. 이번 서버 로그에는 확인한 CUDA 오류 표현도 없었습니다. 장비와 실행 환경을 함께 바꿨으므로 기존 GPU의 물리적 고장 여부는 판단할 수 없습니다.

현재 설정에서는 Qwen의 조건 이해와 근거 준수가 상대적으로 나왔습니다. 그래도 최종 성공은 44개 중 15개뿐입니다. 생성 답변이 맞아도 서비스 검사에서 차단된 사례가 있어 모델 선택과 함께 차단 이유를 검토해야 합니다.

각 모델 60개 비교는 미완료입니다. Bllossom 16개가 남았습니다. 추가 유료 실행이나 CPU 시험은 진행하지 않았으며, 기존 45+8문장 결과와 300문장 질문·실패 기록을 보존했습니다.

Qwen3.5-9B / S014-A: 따라서 같은 해 5 월 31 일은 정기신청 기간에 포함되지만, 6 월 1 일은 정기신청 기간에 포함되지 않습니다.

제공된 원문의 신청 기간에 두 날짜를 각각 적용한 답변입니다. 실제 최신 일정 안내를 평가한 사례는 아닙니다.

A.X-4.0-Light / S036-B: 올해 한도 안에서 지원 가능합니다.

이번 수리비 18만원만 보고 확정했습니다. 연간 지원 횟수와 누적액이 없어 올해 남은 한도는 확인할 수 없습니다.

Bllossom-3B / S032-C: 이 채팅은 '주택금융공사 월세자금보증' 정책에 대한 질문만 답할 수 있어요. 다른 정책이나 새로운 검색은 메인 화면에서 다시 물어봐 주세요.

정책에 관한 질문인데 일반 안내로 끝났습니다. 별도 조건 이해 단계에서는 제시된 31세 외에 1955-03-01 생일을 만들어 최종 나이가 71세로 계산됐습니다.